【论文笔记】Transformer paper：Attention is All You Need（Google，2017）

Arthur Chu Zheng 2020-06-05 Last Modified: 2020-06-05

目录

目录展开 / 收起 Expand/Collapse

- 概览
- 1 Introduction
- 2 Background
- 3 Model Architecture
  - 3.1 Encoder and Decoder Stacks
  - 3.2 Attention
    - 3.2.1 Scaled Dot-Product Attention
    - 3.2.2 Multi-Head Attention
    - 3.2.3 Attention in Transformer
  - 3.3 Position-wise Feed-Forward Networks
  - 3.4 Embeddings and Softmax
  - 3.5 Positional Encoding（位置编码）
  - 3.6 Why Self-Attention
  - 3.7 Training
  - 3.8 Training Data and Batching
  - 3.9 Hardware and Schedule
  - 3.10 Optimizer
  - 3.11 Regularization
    - Residual Dropout
    - Label Smoothing（标签平滑）
- 4 结果
  - 4.1 Machine Translation
  - 4.2 Model Variations
  - 4.3 English Constituency Parsing
- 5 Conclusion
- 参考文献
- 致谢
- Attention 的可视化
  - Attention 在英语中不以及物的理解方式
  - 代词消解 Attention Head 的可视化
- 讨论 Discuss

概览

Google 的 Ashish Vaswani 等人的 **Transformer**模型，开创性地，不使用 RNN 或 CNN 来处理序列数据，而是完全地基于 Attention 机制来处理序列数据。

Transformer 模型在 WMT 2014 English-to-German 翻译任务上，以 28.4 BLEU 的成绩，比现有最佳成绩（包括集成模型）提高了 2 BLEU 以上。

Transformer 模型在 WMT 2014 English-to-French 翻译任务上，在 8 个 GPU 上经过 3.5 天的训练，模型的单项成绩达到了 41.8 BLEU 的新纪录，其训练成本仅仅是文献中最佳模型的一小部分。

Transformer 模型在大规模和有限训练数据的情况下，成功地将其应用于英语句法成分分析，表现出良好的结果。

1 Introduction

1.1 RNN，LSTM 和 GRU 是序列建模和转换问题的最佳方法

1.2 Attention 机制

1.3 Transformer：通过 Attention 来 Draw Global Dependencies

2 Background

2.1 Extended Neural GPU

2.2 ByteNet

2.3 Conv S2S

2.4 Self-Attention

2.5 End-to-end memory networks

2.6 Transformer：通过 Self-Attention 来 Draw Global Dependencies

3 Transformer 模型架构

3.0 Encoder-decoder structure：Sequence transduction 模型的通用结构

3.1 Encoder and Decoder Stacks：Encoder 和 Decoder 的 Stacks

3.2 Attention：Attention 函数的本质是将 Query 和 Key-Value 键值对的集合映射到输出上，其中 Query、Key、Value 和输出都是向量。输出是 Value 的权重和，其中分配给每个 Value 的权重是由 Query 与相应 Key 的兼容性函数计算。

3.2.1 Scaled Dot-Product Attention：Scaled Dot-Product Attention 的 Mask 矩阵

3.2.2 Multi-Head Attention：Multi-Head Attention 的 Mask 矩阵

3.2.3 Attention in Transformer：Transformer 中的 3 种 Attention 机制的具体实现

3.3 Position-wise Feed-Forward Networks：Position-wise 的 Feed-Forward Networks

3.4 Embeddings and Softmax：Embeddings 和 Softmax 的权重矩阵

3.5 Positional Encoding（位置编码）：Positional Encoding 的 Sin/Cos 函数

3.6 Why Self-Attention：Self-Attention 的 3 个优点

3.7 Training：Transformer 的训练

3.8 Training Data and Batching：Training Data 的 Batching 方法

3.9 Hardware and Schedule：Transformer 的硬件和调度

3.10 Optimizer：Transformer 的 Optimizer 是 Adam 算法

3.11 Regularization：Transformer 的 Regularization 方法

- Residual Dropout：Residual Dropout 的 Keep_Prob 是 0.9
- Label Smoothing（标签平滑）：Label Smoothing 的 Epsilon 是 0.1

4 结果

4.1 Machine Translation：Transformer 在 WMT 2014 English-to-German 翻译任务上的成绩，Transformer 在 WMT 2014 English-to-French 翻译任务上的成绩

4.2 Model Variations：Transformer 的 Model Variations 的 Ablation Study

4.3 English Constituency Parsing：Transformer 在 English Constituency Parsing 任务上的成绩

5 Conclusion

参考文献

致谢

Attention 的可视化

Attention 在英语中不以及物的理解方式

代词消解 Attention Head 的可视化

讨论 Discuss

CC BY-NC-SA 4.0 | 本作品采用 知识共享署名-非商业性使用-相同方式共享 4.0 国际许可协议进行许可。